

# 소음 환경의 공장 상황에서 베어링 결함 검사를 위한 **SSA-SL** 트랜스포머에 관한 연구

*May 18, 2022*

학번 : 2020712755

학과 : 스마트팩토리 융합학과

이름 : 이 서영

# Paperworks

- 한국통신학회 추계학술발표대회, pp. 144-145, 2021년 11월 ;클래스 편향된 전류 및 진동 데이터를 위한 강건한 특성인자 추출기법  
=> 본격적으로 기계시설물 이상감지에 사용하는 진동 데이터에 대한 연구를 시작함
- The 5th International Conference on Emerging Data and Industry 4.0 (EDI40), Volume 201, pp. 519-526, March 22 - 25, 2022, Porto, Portugal ;Two Phases Anomaly Detection Based on Clustering and Visualization for Plastic Molding Injection Data  
⇒ 기계시설물 이상감지 및 클래스편향에 관한 연구를 진행함, 특히 문제를 해결하는 AI와 전처리 프레임워크에 대해 심도있게 연구함
- MDPI Electronics Journal (Special Issue: Advances in Fault Detection/Diagnosis of Electrical Power Devices), 11(9), 1504, 7 May 2022 ;SSA-SLTransformer Bearing Fault Diagnosis under Noisy Factory Environments

# Contents

---

- Introduction
- Related Work
- SSA-SLTransformer 제안
- Experiments and Results
- Conclusion

# 1. Introduction

## 기존연구의 한계

---

- 베어링 결함 감지 연구들 중 최신 경향의 인공지능 신경망 모델을 적용한 연구가 부족함
- 베어링 결함감지 연구에 적용하는 전처리 기법에 대한 연구가 부족함, 특히 노이즈 관련된 연구가 전무했음
- 공장의 다양한 상황을 가정하거나 실제로 실험한 연구가 부족함

## Contributions

---

-베어링 결함 감지 연구들 중 최신 경향의 인공지능 신경망 모델을 적용한 연구가 부족함

=> 최신 경향을 반영하여 트랜스포머 모델을 연구에 적용함

-베어링 결함감지 연구에 적용하는 전처리 기법에 대한 연구가 부족함, 특히 노이즈 관련된 연구가 전무했음

=> SSA 알고리즘을 재조명하고, 노이즈에 강건함을 보여줌

-공장의 다양한 상황을 가정하거나 실제로 실험한 연구가 부족함

=> 베어링 데이터에 노이즈를 섞어서, 공장의 혼잡한 상황을 가정함

## **2. Related Work**

---

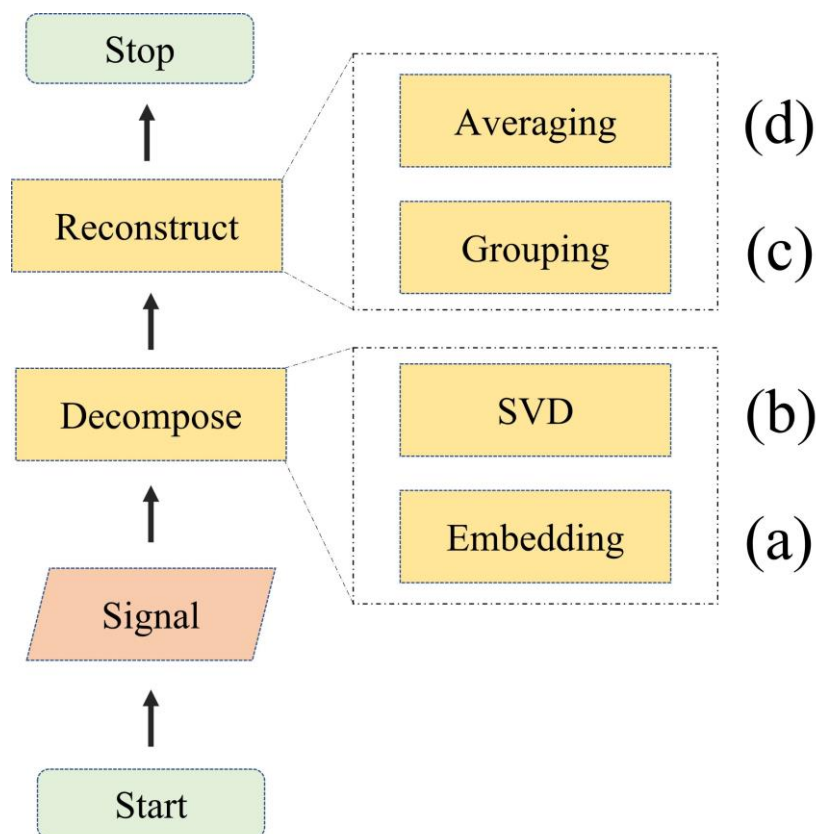
## 베어링 결함 진단

- 기존의 선행연구는 통계적 방법론과 머신러닝적 접근법이 다수를 이루었음
- 딥러닝 도입 이후, 베어링 결함 진단과 딥러닝 접근의 수요가 급격히 상승함
- 그 후 RNN, CNN, Autoencoder 계열 인공지능 모델이 주류를 이루었음
- Class imbalanced, few-shot 문제 등 다양한 방법으로 베어링 결함 진단 선행연구가 있었음

출처 : Hoang, Duy-Tang, and Hee-Jun Kang. "A survey on deep learning based bearing fault diagnosis." Neurocomputing 335 (2019): 327-335.

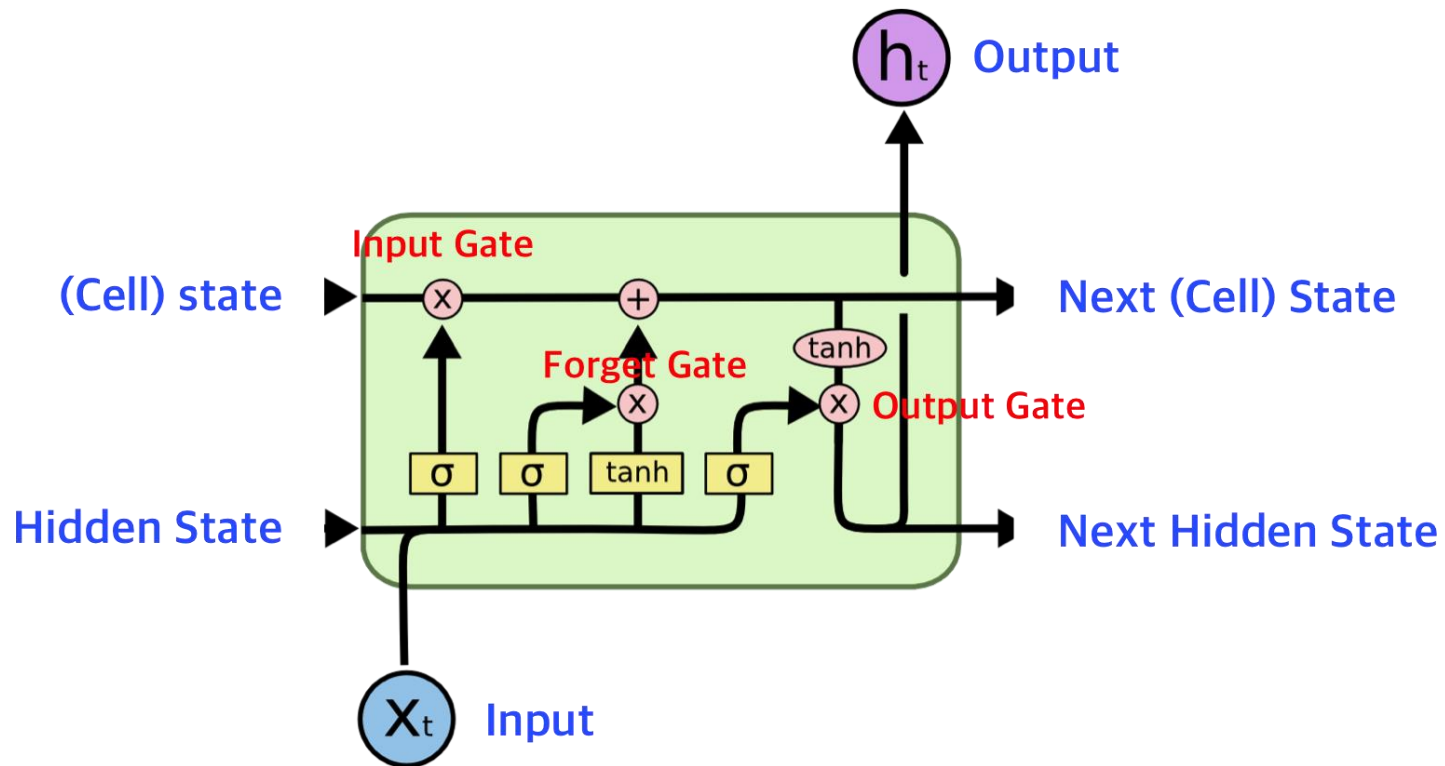


# Singular Spectrum Analysis



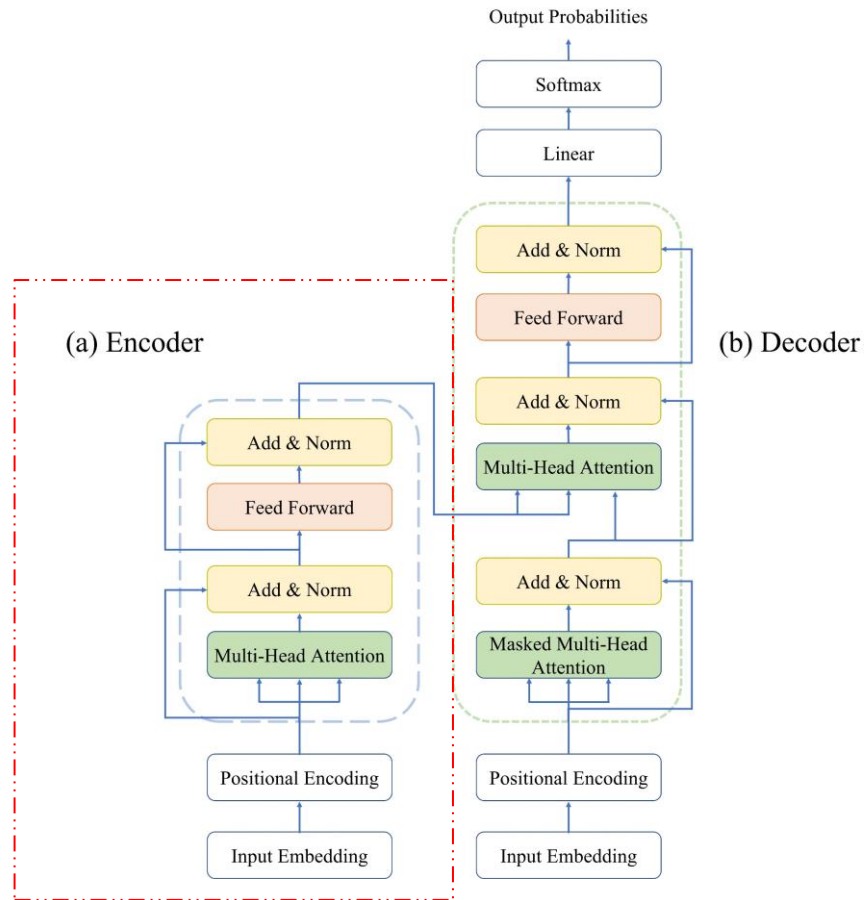
출처 : Rodrigues, Paulo Canas, et al. "The decomposition and forecasting of mutual investment funds using singular spectrum analysis." Entropy 22.1 (2020): 83.

# LSTM



출처 : Greff, Klaus, et al. "LSTM: A search space odyssey." *IEEE transactions on neural networks and learning systems* 28.10 (2016): 2222-2232.

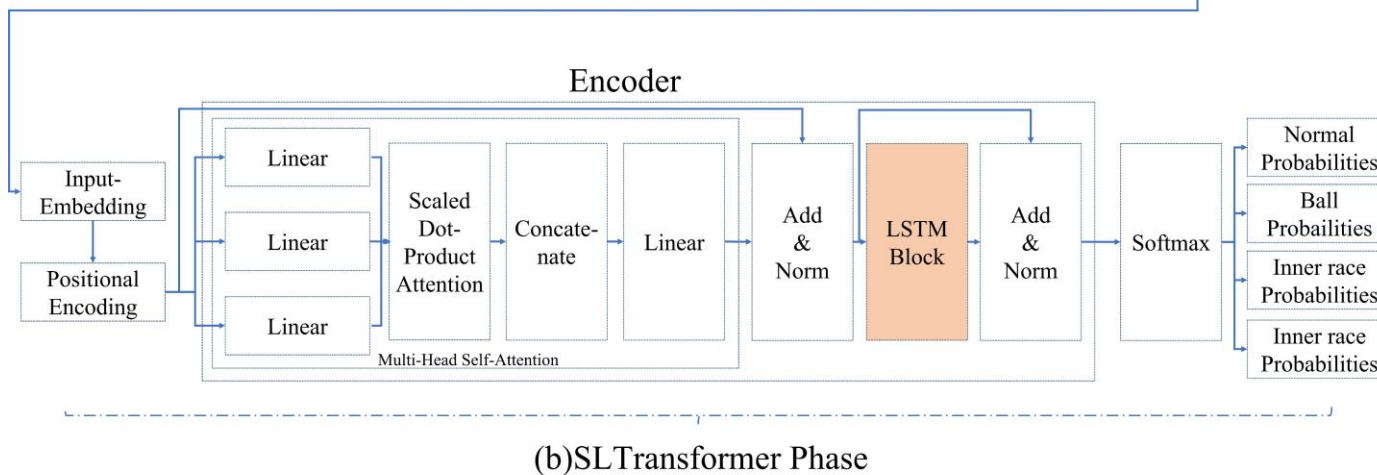

# Vanilla Transformer



출처 : Vaswani, Ashish, et al. "Attention is all you need." *Advances in neural information processing systems* 30 (2017).

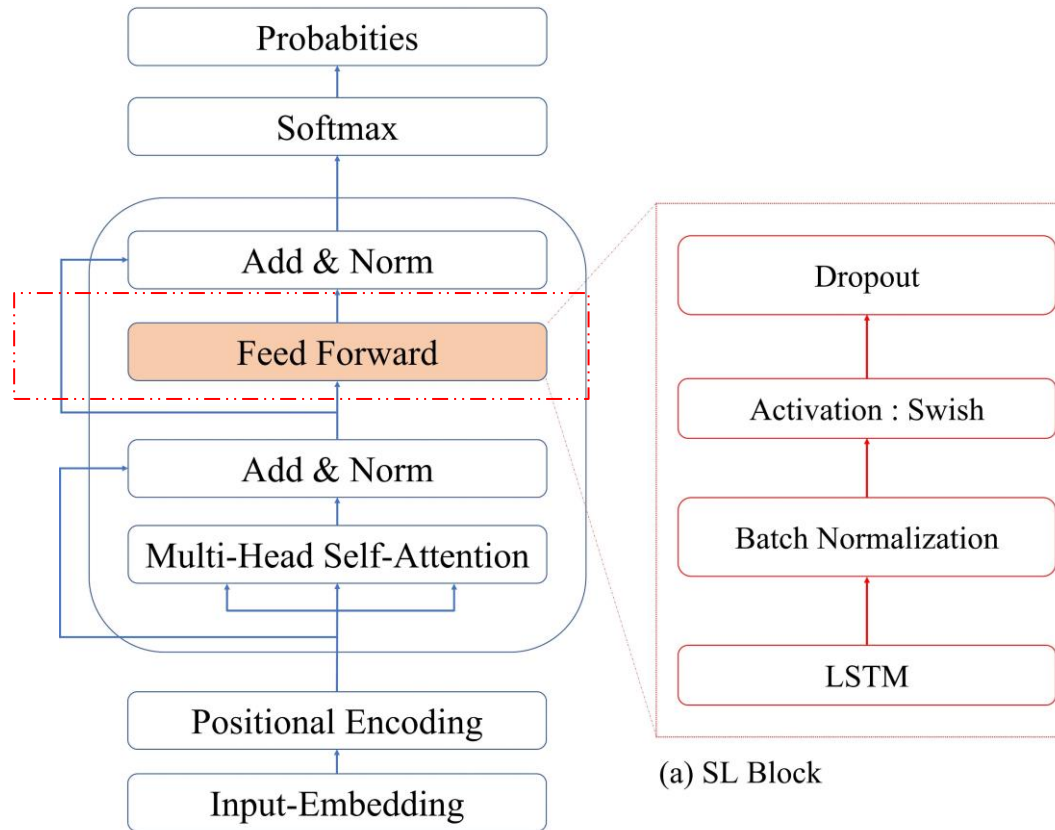
# SSA-SLTransformer 제안

# 아키텍처



MDPI Electronics Journal (Special Issue: Advances in Fault Detection/Diagnosis of Electrical Power Devices), 11(9), 1504, 7 May 2022 ;SSA-SLTransformer Bearing Fault Diagnosis under Noisy Factory Environments

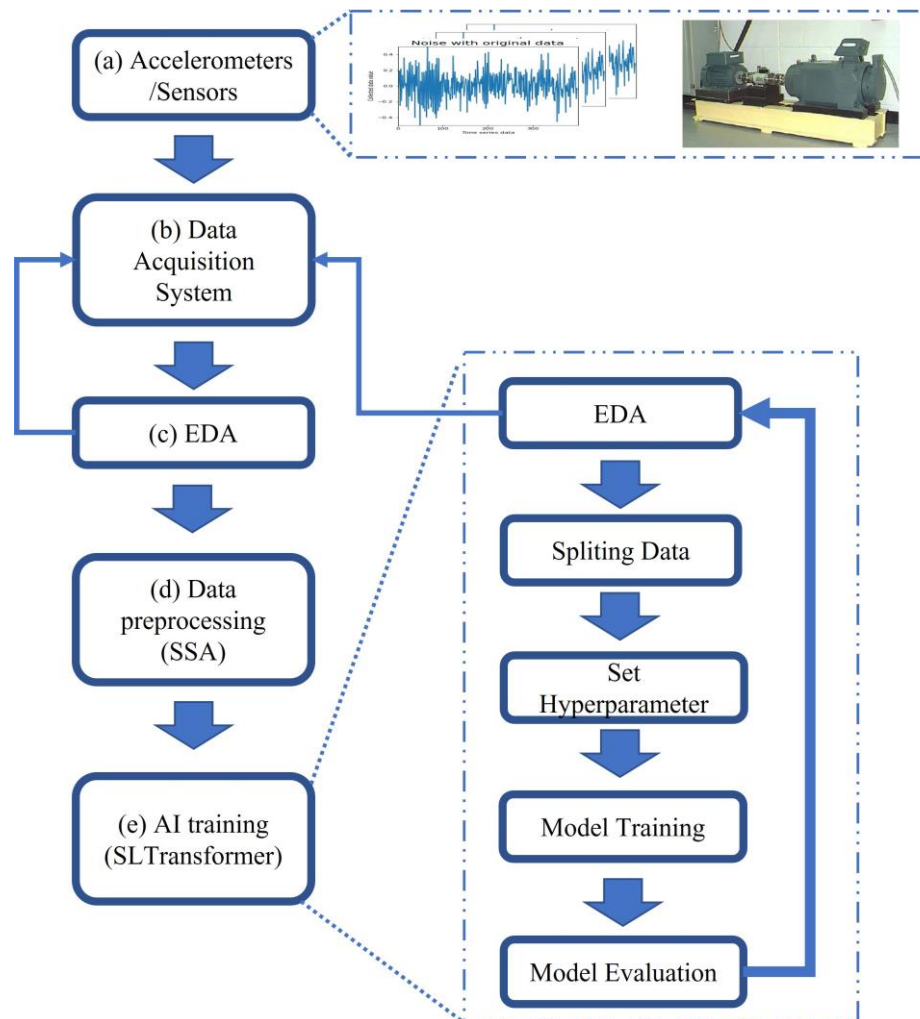
## 세부 아키텍처 설명



- 기존의 **Feed Forward**를 (a)로 구성함
- Activation Function을 **Swish**로 선택함

출처 : Ioffe, Sergey, and Christian Szegedy. "Batch normalization: Accelerating deep network training by reducing internal covariate shift." *International conference on machine learning*. PMLR, 2015.

# SSA-SLTransformer 최적화 절차



# Experiment and Results




## 실험 환경

---


Hardware Environment	Software Environment
Intel core I7 - 9750h CPU @ 2.60 GHz 2.59 GHz 32.0 Gb ram, Nvidia GeForce GTX in 3080.	Python 3.8 Tensorflow==2.2.0 Numpy==1.19.2 Pandas==0.24.2 Matplotlib==3.0.2

## 데이터 셋 설명

- Case Western Reserve University (CWRU) 베어링 데이터 셋은 베어링 전문 연구를 위해 수집된 베어링 데이터 셋임
- (a)는 베어링 데이터 셋이 수집된 시뮬레이터, (b)는 시뮬레이터의 단면임
- 진동 신호는 16채널 DAT 레코더를 사용하여 수집되고 Matlab 환경에서 후처리 되었음




(a)



(b)

## Experiments and Results


- EDM이라는 기계시설물을 통해 시뮬레이터에 강제적인 압력을 주어 결함을 만들고, 결함 데이터를 수집함




Label	Numbers
Normal	4244
Ball	4860
Inner Race	4862
Outer Race	8529

Train	Test	Validation
60%	20%	20%


# Denoise with SSA




- 가우시안 백색 노이즈 데이터 시각화 자료



- Inner Race 결함 중 하나의 예시, Original Data 시각화 자료


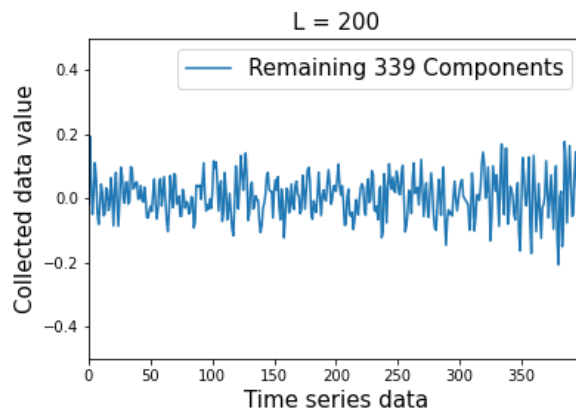




- 노이즈와 Original Data 를 합친 시각화 자료






- SSA가 노이즈를 분해하고 데이터를 재구성한 결과물

## Denoise with SSA ( $L = 200$ )



# Denoise with SSA ( $L = 20$ )




## (1) Denoise with SSA



L값이 충분하지 않아 노이즈가 잘 분해되지 않음을 확인

# ***Denoise with SSA ( $L = 100$ )***


## (1) Denoise with SSA



$L=20$  보다 순수한 성능으로 노이즈를 분해함을 확인  
 그러나 원본 노이즈에 비해 부족함을 확인

## Swish activation function

- BERT 논문에서 저자는 ReLU대신 GeLU를 사용하는 이유로, underbound가 깊기때문에 gradient vanishing이 덜 생기는 것이라 주장함
- Text Generation 분야보다 시간적인 특성이 더 중요한 시계열 데이터이므로 좀 더 gradient vanishing이 덜 할 것이라 예상되는 Swish를 제시하여 time series 속성 feature를 잘 전달할 수 있을것이라 기대함





# Metrics

---


$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Recall = \frac{TP}{TP + FN}$$

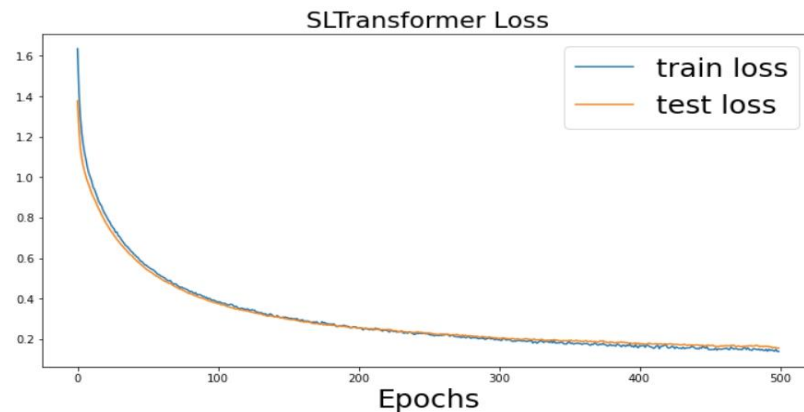

$$Precision = \frac{TP}{TP + FP}$$

$$F1 - score = 2 \frac{Precision \times Recall}{Precision + Recall}$$

## Results (첫번째 실험)



← Input data



- 첫번째 실험은, 노이즈가 섞이지 않은 **CWRU** 데이터에 인공지능 모델을 학습함
- 높은 성능이 나올 것으로 예상하고 예상한 결과를 내놓음
- 그러나 이는 실제 공장 상황에서 비현실적인 상황


## Results (첫번째 실험)

Model	SVM	CNN	LSTM	Transformer	SLTransformer
Accuracy	64.32	85.69	90.15	93.47	95.54
F1-score	57.44	84.44	89.72	92.31	94.47

Table 1 – 첫번째 실험 Accuracy와 F1-score 표.

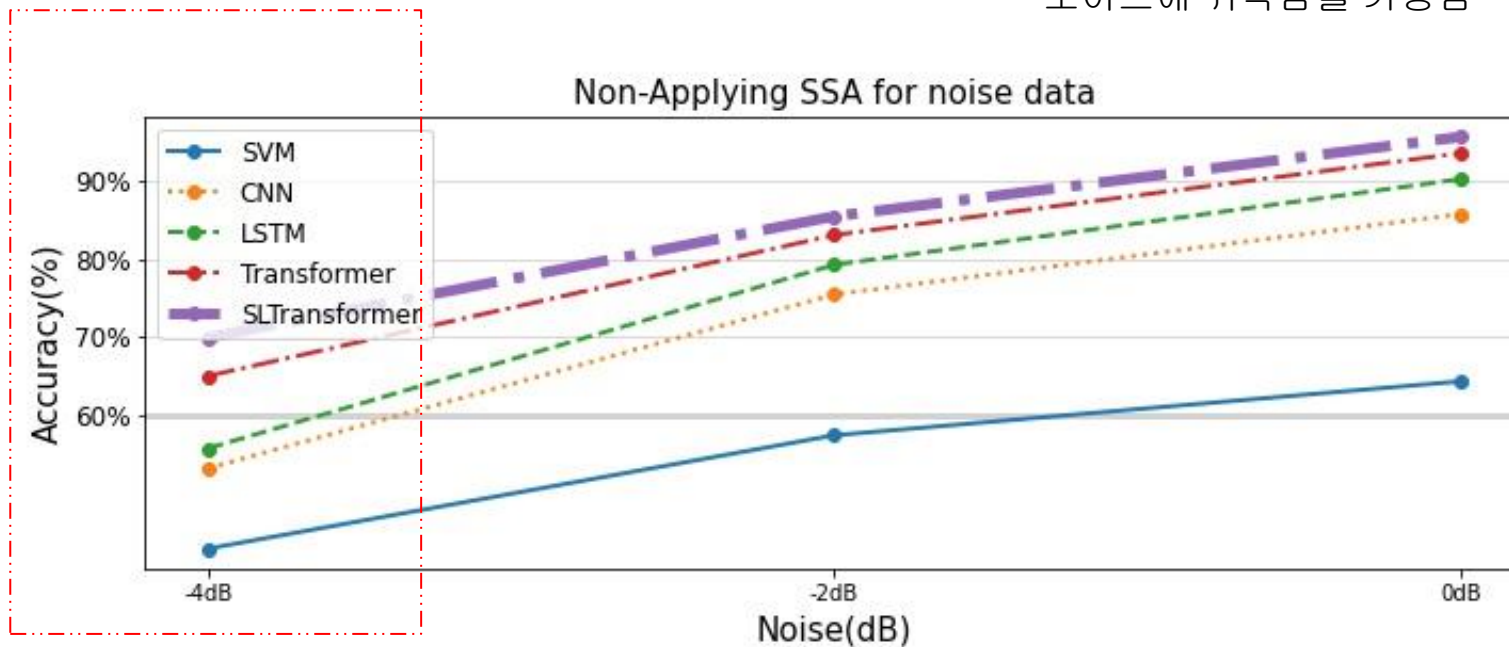
- 첫번째 실험은, 노이즈가 섞이지 않은 **CWRU** 데이터에 인공지능 모델을 학습함
- 높은 성능이 나올 것으로 예상하고 예상한 결과를 내놓음
- 그러나 이는 실제 공장 상황에서 비현실적인 상황

## Results (두번째 실험)



← Input data

- 두번째 실험은 노이즈가 섞인 데이터를 통해 인공지능 모델이 노이즈에 취약함을 가정함



## Results (두번째 실험)

Model	-4dB	-2dB	0dB
SVM	42.95	57.43	64.32
CNN	53.21	75.42	85.69
LSTM	55.76	79.21	90.15
Transformer	65.00	83.01	93.47
SLTransformer	69.89	85.40	95.54


Table 2 – SSA 알고리즘 미적용 Accuracy 표.

Model	-4dB	-2dB	0dB
SVM	54.79	55.44	57.44
CNN	59.44	61.15	84.44
LSTM	61.55	64.31	89.72
Transformer	64.16	68.51	92.31
SLTransformer	68.13	74.10	94.47

Table 3 – SSA 알고리즘 미적용 F1-score 표.


- 전체적으로 성능이 하락했음을 확인
- 노이즈에 취약함을 확인

## Results (세번째 실험)



← Input data

- 세번째 실험은 노이즈가 섞인 데이터를에 SSA 전처리를 진행함
- SSA를 거치고 나서 준수한 성능을 낼 것을 예상



## Results (세번째 실험)

Model	-4dB	-2dB	0dB
SVM	50.10	60.98	65.33
CNN	67.00	80.95	86.88
LSTM	81.10	85.97	91.25
Transformer	83.55	87.42	94.17
SLTransformer	85.55	89.95	96.55

Table 4 – SSA 알고리즘 적용 Accuracy 표.

Model	-4dB	-2dB	0dB
SVM	49.98	59.15	64.17
CNN	65.43	79.95	85.79
LSTM	77.42	82.44	90.01
Transformer	82.11	85.17	93.15
SLTransformer	84.00	86.37	95.33

Table 5 – SSA 알고리즘 적용 F1-score 표.

- 노이즈를 잘 해결했음을 확인

# Conclusion



## 연구결과 & 향후 연구 계획

연구결과 :

- 최신 경향을 반영하여 트랜스포머 모델을 연구에 적용함
- SSA 알고리즘을 재조명하고, 노이즈에 강건함을 보여줌
- 베어링 데이터에 노이즈를 섞어서, 공장의 혼잡한 상황을 가정함
- 3건의 실험을 진행, 일반 CWRU 데이터셋에 SLTransformer가 준수한 성능을 내는 것을 확인
- 두번째 실험에서 인공지능 모델이 노이즈에 취약함을 확인
- 세번째 실험에서 SSA가 노이즈 문제를 해결함을 확인

향후 연구 계획 :

본 연구의 목적은 실제 공장환경을 가정한 연구, 실제 공장에서 센서로 데이터를 수집 후 본 프레임워크가 잘 작동하는지 확인하는 것이 목표

지금까지 발표를 들어주셔서 감사합니다.

---

